



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего
образования
«Московский государственный технический университет имени Н.Э.
Баумана (национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления

КАФЕДРА Системы обработки информации и управления (ИУ5)

ОТЧЁТ **по лабораторной работе №2**

По курсу: «Технологии машинного обучения»

«Изучение библиотек обработки данных»

Выполнил: студент группы
ИУ5-64Б

(Подпись, дата) Евсюков Н.М.
(Ф.И.О.)

Проверил:

(Подпись, дата) Гапанюк Ю.Е.
(Ф.И.О.)

2020 г.

1. Цель работы

Изучение библиотеки обработки данных Pandas.

2. Описание задания

- Выполнить первое демонстрационное задание "demo assignment" под названием "Exploratory data analysis with Pandas" со страницы курса <https://mlcourse.ai/assignments>.
- Сформировать отчет и разместить его на своем репозитории GitHub.

3. Текст программы и экранные формы с примерами

выполнения программы

```
[ ] import numpy as np
import pandas as pd
```

```
data = pd.read_csv('adult.data.txt')
data.head()
```

	age	workclass	fnlwgt	education	education-num	marital-status	occupation	relationship	race	sex	capital-gain	capital-loss	hours-per-week	native-country	salary
0	39	State-gov	77516	Bachelors	13	Never-married	Adm-clerical	Not-in-family	White	Male	2174	0	40	United-States	<=50K
1	50	Self-emp-not-inc	83311	Bachelors	13	Married-civ-spouse	Exec-managerial	Husband	White	Male	0	0	13	United-States	<=50K
2	38	Private	215646	HS-grad	9	Divorced	Handlers-cleaners	Not-in-family	White	Male	0	0	40	United-States	<=50K
3	53	Private	234721	11th	7	Married-civ-spouse	Handlers-cleaners	Husband	Black	Male	0	0	40	United-States	<=50K
4	28	Private	338409	Bachelors	13	Married-civ-spouse	Prof-specialty	Wife	Black	Female	0	0	40	Cuba	<=50K

```
[ ] data['sex'].value_counts()
```

```
Male      21790
Female    10771
Name: sex, dtype: int64
```

```
[ ] data.loc[data['sex'] == 'Female', 'age'].mean()
```

```
36.85823043357163
```

```
[ ] float((data['native-country'] == 'Germany').sum()) / data.shape[0]
```

```
0.004207487485028101
```

```
[ ] ages1 = data.loc[data['salary'] == '>50K', 'age']
ages2 = data.loc[data['salary'] == '<=50K', 'age']
print("Средний возраст богатых: {0} +- {1} лет, бедных - {2} +- {3} лет.".format(
    round(ages1.mean()), round(ages1.std(), 1),
    round(ages2.mean()), round(ages2.std(), 1)))
```

```
Средний возраст богатых: 44 +- 10.5 лет, бедных - 37 +- 14.0 лет.
```

```
[ ] data.loc[data['salary'] == '>50K', 'education'].unique() # No
```

```
↳ array(['HS-grad', 'Masters', 'Bachelors', 'Some-college', 'Assoc-voc',  
        'Doctorate', 'Prof-school', 'Assoc-acdm', '7th-8th', '12th',  
        '10th', '11th', '9th', '5th-6th', '1st-4th'], dtype=object)
```

```
[ ] for (race, sex), sub_df in data.groupby(['race', 'sex']):  
    print("Paca: {0}, пол: {1}".format(race, sex))  
    print(sub_df['age'].describe())
```

```
↳ count    192.000000  
   mean      37.208333  
   std       12.049563  
   min       17.000000  
   25%       28.000000  
   50%       35.000000  
   75%       45.000000  
   max       82.000000  
   Name: age, dtype: float64  
Paca: Asian-Pac-Islander, пол: Female  
count    346.000000  
   mean      35.089595  
   std       12.300845  
   min       17.000000  
   25%       25.000000  
   50%       33.000000  
   75%       43.750000
```

```
[ ] data.loc[(data['sex'] == 'Male') &  
             (data['marital-status'].isin(['Never-married',  
                                           'Separated',  
                                           'Divorced',  
                                           'Widowed']))], 'salary'].value_counts()
```

```
↳ <=50K    7552  
   >50K      697  
   Name: salary, dtype: int64
```

```
[ ] data.loc[(data['sex'] == 'Male') &  
             (data['marital-status'].str.startswith('Married'))], 'salary'].value_counts()
```

```
↳ <=50K    7576  
   >50K     5965  
   Name: salary, dtype: int64
```

```
data['marital-status'].value_counts()
```

```
Married-civ-spouse      14976
Never-married           10683
Divorced                 4443
Separated               1025
Widowed                  993
Married-spouse-absent   418
Married-AF-spouse       23
Name: marital-status, dtype: int64
```

```
[ ] max_load = data['hours-per-week'].max()
    print("Максимальное время - {0} часов/неделя".format(max_load))

    num_workaholics = data[data['hours-per-week'] == max_load].shape[0]
    print("Общее количество трудоголиков {0}".format(num_workaholics))

    rich_share = float(data[(data['hours-per-week'] == max_load)
                           & (data['salary'] == '>50K')].shape[0]) / num_workaholics
    print("Процент богатых их них {0}%".format(int(100 * rich_share)))
```

```
Максимальное время - 99 часов/неделя
Общее количество трудоголиков 85
Процент богатых их них 29%
```

```
[ ] for (country, salary), sub_df in data.groupby(['native-country', 'salary']):
    print(country, salary, round(sub_df['hours-per-week'].mean(), 2))
```

```
? <=50K 40.16
? >50K 45.55
Cambodia <=50K 41.42
Cambodia >50K 40.0
Canada <=50K 37.91
Canada >50K 45.64
China <=50K 37.38
China >50K 38.9
Columbia <=50K 38.68
Columbia >50K 50.0
Cuba <=50K 37.99
Cuba >50K 42.44
Dominican-Republic <=50K 42.34
Dominican-Republic >50K 47.0
Ecuador <=50K 38.04
Ecuador >50K 48.75
El-Salvador <=50K 36.03
El-Salvador >50K 45.0
England <=50K 40.48
England >50K 44.53
France <=50K 41.06
France >50K 50.75
Germany <=50K 39.14
Germany >50K 44.98
- - - - -
```

```
[ ] pd.crosstab(data['native-country'], data['salary'],
               values=data['hours-per-week'], aggfunc=np.mean).T
```



native-country	?	Cambodia	Canada	China	Columbia	Cuba	Dominican-Republic	Ecuador	El-Salvador	England	France	Germany	Greece
salary													
<=50K	40.164760	41.416667	37.914634	37.381818	38.684211	37.985714	42.338235	38.041667	36.030928	40.483333	41.058824	39.139785	41.809524
>50K	45.547945	40.000000	45.641026	38.900000	50.000000	42.440000	47.000000	48.750000	45.000000	44.533333	50.750000	44.977273	50.625000

